

Guide Étudiants — Finale Hackathon CND

Version : Finale — Mai 2026

Destinataires : Équipes participantes (EPITA, ESGI, ECE)

Durée : 2 heures

Table des matières

1. Contexte de la finale
 2. Votre mission
 3. Accès aux données
 4. Les challenges
 5. Format de soumission
 6. Système de scoring
 7. Soumission via le portail
 8. Conseils stratégiques
 9. FAQ
-

1. Contexte de la finale

Vous êtes l'équipe SOC (Security Operations Center) d'une entreprise qui a subi une **journée complète de cyberattaques multiples et simultanées**. Votre infrastructure a généré des millions de logs pendant cette journée critique.

Votre mission : détecter et analyser automatiquement des cyberattaques à partir de logs bruts, et proposer des action de remédiation dans un environnement cloud AWS.

Ce qui change par rapport au Dataset 1

	Dataset 1 (Dev)	Dataset 2 (Finale)
Volume	~21 millions de logs	~25 millions de logs
Challenges	5 attaques	Plus d'attaques (à vous de les trouver)
Ground truth	Fourni	Non fourni
Durée couverte	30 jours (janvier 2026)	16 heures (06:00 → 22:00)
Difficulté	Moyenne	Élevée
Soumissions	-	Illimitées (améliorez vos scores)

2. Votre mission

Pour chaque attaque détectée, vous devez identifier :

1. **Le type d'attaque** : Quelle catégorie d'attaque est-ce ?
2. **Les IPs attaquantes** : D'où vient l'attaque ?
3. **Les comptes victimes** : Qui a été ciblé ? (si applicable)
4. **La fenêtre temporelle** : Quand l'attaque a-t-elle commencé et fini ?
5. **Les indicateurs de compromission (IOC)** : Quelles preuves avez-vous trouvées ?

3. Accès aux données

3.1 OpenSearch Dashboards (interface web)

URL	<code>https://search-hackathon-cnd-finale-gqskvwuwmhjxrfsumj7wqlfji.eu-west-3.es.amazonaws.com/_dashboards/</code>
Username	etudiant
Password	Hackathon2026!Read
Index	logs-raw
Accès	Lecture seule

3.2 Volume de données

- ~**25 millions de logs** sur 16 heures
- Plage temporelle : **15 mai 2026, 06:00 → 22:00 UTC**
- Mix de trafic normal (bruit de fond) et d'attaques

3.3 Accès API (Python)

```
import requests
```

```
OS_URL = "https://search-hackathon-cnd-finale-gqskvwuwmhjxrfsumj7wqlfji.eu-west-3.es.amazonaws.com"
AUTH = ("votre_user", "votre_password")
```

```
# Compter les documents
```

```
r = requests.get(f"{OS_URL}/logs-raw/_count", auth=AUTH)
print(f"Total logs: {r.json()['count']:,}")
```

```
# Rechercher des logs sur une plage horaire
```

```
query = {
    "query": {
        "bool": {
            "must": [
```

```

        {"range": {"timestamp": {"gte": "2026-05-15T09:00:00Z", "lt":
"2026-05-15T10:00:00Z"}}}
    ]
    },
    "size": 100,
    "sort": [{"timestamp": "asc"}]
}
r = requests.post(f"{OS_URL}/logs-raw/_search", auth=AUTH, json=query)
hits = r.json()["hits"]["hits"]

```

3.4 Astuce : Utiliser les agrégations pour explorer

Top source_ip par nombre d'occurrences

```

agg_query = {
    "size": 0,
    "query": {"range": {"timestamp": {"gte": "2026-05-15T06:00:00Z", "lt": "2
026-05-15T22:00:00Z"}}},
    "aggs": {
        "top_ips": {
            "terms": {"field": "source_ip", "size": 20}
        }
    }
}
r = requests.post(f"{OS_URL}/logs-raw/_search", auth=AUTH, json=agg_query)
for bucket in r.json()["aggregations"]["top_ips"]["buckets"]:
    print(f"  {bucket['key']}: {bucket['doc_count']:,} logs")

```

4. Les challenges

Vous devez détecter **toutes les attaques** qui se sont déroulées pendant la journée. Les attaques peuvent se chevaucher dans le temps.

- ❑ **C'est à vous de déterminer combien d'attaques ont eu lieu, de quel type elles sont, et de les caractériser.**

Ce que vous devez trouver pour chaque attaque :

- **Le type d'attaque** (utilisé comme challenge_id lors de la soumission)
- **Les IPs attaquantes** (une ou plusieurs)
- **Les comptes victimes** (si applicable — certaines attaques n'en ont pas)
- **La fenêtre temporelle** (début et fin de l'attaque)
- **Les indicateurs de compromission** (IOC) : preuves techniques que vous avez trouvées

Convention de nommage pour le challenge_id

Le challenge_id correspond au **type d'attaque** que vous avez détecté, en snake_case. Exemples de formats acceptés :

- sql_injection
- brute_force
- credential_stuffing
- etc.

Le système accepte des variantes courantes. Utilisez un nom descriptif et standardisé.

Rappel : Vous connaissez déjà certains types d'attaques du Dataset 1. Le Dataset 2 contient les mêmes types ET de nouveaux types.

5. Format de soumission

Pour chaque challenge, soumettez un JSON avec la structure suivante :

```
{
  "attack_type": "credential_stuffing",
  "attacker_ips": ["103.201.46.10", "178.62.10.12"],
  "victim_accounts": ["mmartin"],
  "attack_start_time": "2026-05-15T06:00:00Z",
  "attack_end_time": "2026-05-15T09:00:00Z",
  "indicators": {
    "failed_logins": "~1000",
    "web_shell": "/uploads/report_2000.php",
    "reverse_shell_port": 3333,
    "geolocation": "Stockholm"
  }
}
```

Détails des champs

Champ	Type	Obligatoire	Description
attack_type	string	✓	Type d'attaque (voir tableau ci-dessus)
attacker_ips	string[]	✓	Liste des IPs attaquantes
victim_accounts	string[]	✓	Comptes ciblés (liste vide [] si non applicable)
attack_start_time	string	✓	Début de l'attaque (format ISO 8601 UTC)
attack_end_time	string	✓	Fin de l'attaque (format ISO 8601 UTC)
indicators	object	✓	Preuves techniques (clés libres, valeurs libres)

À propos des indicators (IOC)

Le champ indicators est un objet libre. Vous choisissez les noms de clés. Ce qui compte c'est les valeurs que vous fournissez.

Exemples de ce que vous pouvez mettre : - Nombre de tentatives échouées - Chemins de fichiers suspects - Ports utilisés - Binaires malveillants trouvés - Volumes de données exfiltrées - Patterns d'attaque identifiés

Important : Plus vous fournissez d'indicateurs pertinents, plus votre score sera élevé. Mais des indicateurs faux ne vous pénalisent pas — ils sont simplement ignorés.

6. Système de scoring

Barème (100 points par challenge)

Critère	Points	Description
Type d'attaque	20 pts	Correct = 20, famille correcte = 10, faux = 0
IPs attaquantes	20 pts	Score F1 (précision × rappel)
Comptes victimes	20 pts	Score F1
Timeline	20 pts	±5 minutes de tolérance
Indicateurs (IOC)	20 pts	Proportionnel aux valeurs pertinentes trouvées

Grades

Score	Grade
≥ 95	A+
≥ 85	A
≥ 75	B
≥ 60	C
≥ 40	D
< 40	F

Règles importantes

- **Seuil de validation** : 70/100 minimum pour qu'un challenge soit considéré "résolu"
- **Meilleur score gardé** : si vous re-soumettez un challenge avec un meilleur score, il remplace l'ancien
- **Soumissions illimitées** : vous pouvez soumettre autant de fois que vous voulez
- **Anti-doublon** : si vous soumettez exactement la même détection, elle sera rejetée

- **Score total** = somme des meilleurs scores sur chaque challenge

Comment le score est calculé

IPs attaquantes — Score F1 : - Si vous trouvez toutes les bonnes IPs et seulement celles-là → 20/20 - Si vous en trouvez certaines mais pas toutes → score proportionnel
- Si vous ajoutez des faux positifs → ça baisse le score

Indicateurs — Matching par valeur : - Le système cherche si vos **valeurs** correspondent aux valeurs attendues - Les noms de clés n'ont pas d'importance - Tolérance $\pm 30\%$ pour les nombres - Case-insensitive pour les strings

7. Soumission via le portail

URL du portail

Accédez à l'Innovation Sandbox : <https://dkij2dq25lxs3.cloudfront.net>

Soumission multi-challenges

Vous pouvez soumettre **plusieurs challenges d'un coup** en utilisant le format multi :

```
[
  {
    "challenge_id": "credential_stuffing",
    "detection": { ... }
  },
  {
    "challenge_id": "ssh_brute_force",
    "detection": { ... }
  }
]
```

8. Conseils stratégiques

- **Ne pas confondre bruit de fond et attaque** : Il y a beaucoup de trafic normal
- **Attention aux chevauchements** : Plusieurs attaques peuvent être actives en même temps
- **Vérifiez les ports inhabituels** : Certaines attaques utilisent des ports non-standard
- **Regardez les user-agents** : Des outils d'attaque ont des signatures reconnaissables

9. FAQ

Q : Combien d'attaques dois-je trouver ?

R : C'est à vous de le déterminer ! Chaque type d'attaque n'apparaît qu'une seule fois. Plus vous en trouvez, plus votre score sera élevé.

Q : Est-ce que les attaques se chevauchent dans le temps ?

R : Oui, certaines attaques sont simultanées. La journée entière est couverte de 06:00 à 22:00.

Q : Comment je sais si j'ai trouvé la bonne IP ?

R : Soumettez votre détection et regardez le score. Si le score IPs est à 20/20, vous avez trouvé les bonnes.

Q : Que mettre dans `victim_accounts` si l'attaque ne cible pas un utilisateur spécifique ?

R : Mettez un tableau vide `[]`. Certaines attaques ne ciblent pas un compte utilisateur en particulier.

Q : Les indicators doivent-ils avoir des noms de clés spécifiques ?

R : Non ! Vous pouvez nommer les clés comme vous voulez. Seules les **valeurs** sont évaluées. Par exemple `"nb_echecs": 1000` ou `"failed_attempts": "~1000"` sont équivalents.

Q : Est-ce que je suis pénalisé si j'ajoute des indicators faux ?

R : Non, les indicators qui ne matchent pas sont simplement ignorés. Mais ne mettez que ce dont vous êtes sûr pour garder un rapport clair.

Q : Comment fonctionne le leaderboard ?

R : Le leaderboard affiche la **somme des meilleurs scores** par challenge pour chaque équipe. Plus vous résolvez de challenges, plus votre score total est élevé.

Q : Puis-je re-soumettre un challenge pour améliorer mon score ?

R : Oui ! Soumissions illimitées. Seul le meilleur score par challenge est conservé.

Bonne chance !

L'équipe CND vous souhaite une excellente finale. N'hésitez pas à lever la main si vous avez des questions techniques.